

ΕΞΟΥΞΗ ΔΕΔΟΜΕΝΩΝ

2^η ΣΕΙΡΑ ΑΣΚΗΣΕΩΝ

Ερώτηση 1

//Με χρήση ενός (1) πάσου για παράταση έως 13/1

ΙΩΑΝΝΗΣ ΓΙΑΝΝΑΚΟΣ AM4970

ΕΡΩΤΗΣΗ 1

A. Μία power-law κατανομή ορίζεται ως $P(X=x)=(a-1)x^{-a}$, όπου a είναι ο εκθέτης της κατανομής. Σας δίνεται ένα σύνολο από παρατηρήσεις $X=\{x_1, \dots, x_n\}$ που έχουν παραχθεί από μία power-law κατανομή. Χρησιμοποιήστε την Maximum Likelihood Estimation τεχνική που περιγράψαμε στην τάξη για να βρείτε τον εκθέτη της power-law κατανομής που ταιριάζει (fits) τα δεδομένα των παρατηρήσεων.

Δεδομένα:

- Power-Law κατανομή: $P(X = x) = (a - 1) * x^{-a}$, όπου a ο εκθέτης της κατανομής
- Σύνολο παρατηρήσεων: $X=\{x_1, \dots, x_n\}$ το οποίο έχει παραχθεί από μια Power-law κατανομή

ΛΥΣΗ

Για να χρησιμοποιήσουμε την MLE για τον εκθέτη a της παραπάνω κατανομής, πρέπει να βρούμε την τιμή του a που μεγιστοποιεί την συνάρτηση MLE.

Η MLE για την Power-law κατανομή είναι

$$L(a) = \prod_{i=1}^n P(X = x_i) \Rightarrow L(a) = \prod_{i=1}^n (a - 1) * x_i^{-a}$$

Στη συνέχεια, λογαριθμίζω την παραπάνω συνάρτηση για ευκολία:

$$LL(a) = (a - 1) * \sum_{i=1}^n \log(x_i) - n * \sum_{i=1}^n \log(a - 1)$$

Έπειτα, λύνω την εξίσωση $\frac{\partial LL}{\partial a} = 0$ προκειμένου να βρω την εκτιμώμενη τιμή του εκθέτη a της Power-law κατανομής που ταιριάζει τα δεδομένα των παρατηρήσεων.

Αρχικά, θα παραγωγίσουμε τον πρώτο όρο:

$$\frac{\partial}{\partial a} [(a - 1) * \sum_{i=1}^n \log(x_i)]$$

Άρα θα έχουμε: $\sum_{i=1}^n \log(x_i)$

Στη συνέχεια παραγωγίζουμε τον δεύτερο όρο:

$$\frac{\partial}{\partial \alpha} [-n * \sum_{i=1}^n \log(a - 1)]$$

$$\text{Άρα θα έχουμε: } -n * \sum_{i=1}^n \frac{1}{a-1}$$

Τώρα συνενωνουμε τις παραγώγους και θέτουμε το αποτέλεσμα ίσο με μηδέν για λύσουμε την εξίσωση: $\sum_{i=1}^n \log(x_i) - n * \sum_{i=1}^n \frac{1}{a-1} = 0$

Για να λύσουμε την παραπάνω εξίσωση αθροίζουμε τον πρώτο όρο $\sum_{i=1}^n \log(x_i)$

Ο παραπάνω όρος δεν μπορεί να απλοποιηθεί περαιτέρω

Στη συνέχεια, αθροίζουμε τον δεύτερο όρο $n * \sum_{i=1}^n \frac{1}{a-1}$, συνεπώς εκτελούμε το άθροισμα $n * \frac{n}{a-1}$

Έπειτα, συνενώνουμε τους δύο όρους και θέτουμε το αποτέλεσμα ίσο με μηδέν:

$$\sum_{i=1}^n \log(x_i) - n * \frac{n}{a-1} = 0 \Rightarrow$$

$$\sum_{i=1}^n \log(x_i) = n * \frac{n}{a-1} \Rightarrow (a - 1) = \frac{n}{\sum_{i=1}^n \log(x_i)} \Rightarrow$$

$$a = 1 + \frac{n}{\sum_{i=1}^n \log(x_i)}$$

Συνεπώς, συμπεραίνουμε ότι το a παίρνει τιμές μεγαλύτερες του 1 ($a > 1$).

- B. Υποθέστε ότι οι παρατηρήσεις $X=\{x_1, \dots, x_n\}$ έχουν παραχθεί από ένα μείγμα δύο power-law κατανομών, L_1, L_2 , με παραμέτρους a_1, a_2 , και πιθανότητες μίξης (mixture probabilities) π_1, π_2 . Θα χρησιμοποιήσουμε τον EM αλγόριθμο για να υπολογίσουμε τις παραμέτρους $\theta=(a_1, a_2, \pi_1, \pi_2)$ του mixture μοντέλου, όπως κάναμε και για την περίπτωση της μίξης από Gaussian κατανομές. Στο M βήμα, υποθέτουμε ότι έχουμε τις πιθανότητες ανάθεσης $P(L_k | x_i)$, για $k=1, 2$ και $i=1, \dots, n$, και θέλουμε να υπολογίσουμε τις παραμέτρους θ . Δώστε τις εξισώσεις για τα a_1, a_2, π_1, π_2 και τους υπολογισμούς με τους οποίους τις παρήγατε.

Δεδομένα:

- Power-law κατανομή L1: $P(X = x) = (a_1 - 1) * x^{-a_1}$, όπου a_1 ο εκθέτης της κατανομής
- Power-law κατανομή L2: $P(X = x) = (a_2 - 1) * x^{-a_2}$, όπου a_2 ο εκθέτης της κατανομής
- Σύνολο παρατηρήσεων: $X=\{x_1, \dots, x_n\}$ το οποίο έχει παραχθεί από μείγμα δύο power-law κατανομών L1 και L2 με a_1, a_2 παραμέτρους και π_1, π_2 πιθανότητες μίξης

ΛΥΣΗ

Αρχικά, με πιθανότητα π_1 το μείγμα προέρχεται κυρίως από την κατανομή L1 και αντίστοιχα με π_2 από την κατανομή π_2 .

Συνεπώς, $\pi_1 + \pi_2 = 1$ και $\pi_1 = P(L_1)$, $\pi_2 = P(L_2)$

Έπειτα, έχουμε $P(x_i | L_1) = P(x_i | \theta_1)$ και $P(x_i | L_2) = P(x_i | \theta_2)$, όπου $\theta_1 = a_1$ και $\theta_2 = a_2$

Άρα έχουμε $\theta(\pi_1, \pi_2, \theta_1, \theta_2) \rightarrow \theta(\pi_1, \pi_2, a_1, a_2)$

Για την τιμή θ έχουμε $P(x_i | \theta) = \pi_1 * P(x_i | \theta_1) + \pi_2 * P(x_i | \theta_2)$

Άρα για όλες τις τιμές $X=(x_1, \dots, x_n)$ έχουμε $P(X | \theta) = \prod_{i=1}^n P(x_i | \theta)$

Παρακάτω θα αναλύσουμε τα βήματα του EM Αλγόριθμου

EM Αλγόριθμος: Στο E-Βήμα δοθέντων των παραπάνω παραμέτρων Θ υπολογίζω τις πιθανότητες $P(L1|x_i)$ και $P(L2|x_i)$.

EM Αλγόριθμος: Στο M-Βήμα υπολογίζω τις παραμέτρους που μεγιστοποιούν την συνάρτηση

$$LL(\theta) = \sum_{x_i} \log (\pi_1 * P(x_i|\theta_1) + \pi_2 * P(x_i|\theta_2))$$

Συνεπώς, οι παράμετροι που θέλουμε να υπολογίσουμε είναι τα α_1 , α_2 που υπολογίζονται από τους τύπους:

$$\alpha_1 = \frac{\sum_{i=1}^n P(L1|x_i) * \log (x_i)^2}{\sum_{i=1}^n P(L1|X_i) * \log (x_i)}$$

και

$$\alpha_2 = \frac{\sum_{i=1}^n P(L2|x_i) * \log (x_i)^2}{\sum_{i=1}^n P(L2|X_i) * \log (x_i)}$$

καθώς και τα π_1 , π_2 που υπολογίζονται από τους τύπους

$$\pi_1 = \frac{\sum_{i=1}^n P(L1|x_i)}{n}$$

και

$$\pi_2 = \frac{\sum_{i=1}^n P(L2|x_i)}{n}$$